

Title of paper

Author name^a

^aUniversity of the Moon, , Earth, , ,

Abstract

La rapida diffusione dell'Intelligenza Artificiale sui dispositivi personali solleva dubbi sulla loro sostenibilità ecologica.

Le attuali stime ecologiche si basano su misurazioni lineari derivate dai datacenter, assumendo un costo energetico costante per i token testuali generati.

Attraverso test empirici su hardware consumer, questo studio analizza le metriche di consumo di 7 LLM, dai 3B ai 27B di parametri, isolando il reale impatto energetico dell'inferenza locale.

I risultati confutano l'assunto di linearità della letteratura, dato che l'assorbimento energetico subisce fluttuazioni dettati da vari fenomeni, come il prefill effect, dalla complessità del prompt e dalla saturazione della memoria. L'analisi dimostra come il vero collo di bottiglia energetico e prestazionale nell'IA decentralizzata non risiede nella capacità computazionale, bensì nella larghezza di banda dalla memoria.

Al fine di superare l'inefficacia del puro conteggio dei token, la ricerca formalizza l'esigenza di un nuovo framework di misurazione dinamico basato sui MB, pesato per lo sforzo cognitivo e lo stato architetturale.

Si conclude che la sostenibilità dell'IA consumer non deriva dalla massimizzazione dei parametri, ma dall'allineamento tra la scala dell'algoritmo e i vincoli fisici dell'hardware ospitante.

Keywords:

keyword 1, keyword 2, keyword 3, keyword 4

1. Introduction

Le Intelligenze Artificiali sono passate da ambito di ricerca d'avanguardia ad uno strumento facente parte della quotidianità di milioni di persone. Tuttavia, questa rapida diffusione poggia su un'infrastruttura fisica massiccia con un costo ambientale molto elevato.

Questo costo non è solo in termini elettrici, ma comincia dall'estrazione dei minerali rari, definiti 3TG, passando poi per la fabbricazione stessa dei chip con consumi idrici pari a milioni di litri di acqua ultra pura ogni giorno [1] ed emissioni nell'atmosfera di gas fluorati nocivi [2].

La densità energetica stessa dei singoli rack sta cambiando, passando dai 7-10 kW/rack ad oltre 100 kW/rack [3] con conseguenti modifiche strutturali ai datacenter per consentire il passaggio al raffreddamento a liquido o ad

immersione.

La letteratura esistente si concentra principalmente sui costi della fase del training dei modelli che però avviene una tantum, tralasciando i costi legati all'inferenza dell'utente finale che al contrario rappresenta la maggior parte del ciclo di vita di una sistema AI [4].

Le attuali analisi soffrono di gravi lacune, allo stato dell'arte le misurazioni basate sui token non tengono conto della densità informativa del contenuto generato.

L'omissione di dati fondamentali, da parte dei provider, come i consumi idrici e le emissioni di CO₂ rendono le analisi su modelli open-source per il testing in locale particolarmente necessarie.

Infine le stime attuali si concentrano principalmente su situazioni ideali in ambienti controllati come i datacenter, ignorando casistiche che possano causare rallentamenti o

guasti, aumentando così l'impatto ambientale effettivo su hardware consumer e quindi rendendo le attuali stime di sostenibilità sistematicamente incomplete.

Il contributo fornito da questo lavoro si articola in tre parti principali.

In primo luogo viene introdotta una metrica di densità energetica normalizzata basata sulla dimensione del file generato. Tale approccio punta a permettere di poter confrontare oggettivamente il costo energetico dell'informazione prodotta, superando i limiti attuali del semplice conteggio dei token, il quale risulta inefficiente. In secondo luogo la ricerca presenta un'analisi sperimentale su hardware consumer al fine di mappare i consumi in casi d'uso generici, questo consente di quantificare l'impatto vero dell'utente finale rispetto alle analisi che vengono effettuate presso i datacenter.

Infine i risultati ottenuti forniscono quindi linee guida operative per ricercatori e sviluppatori, mirate a bilanciare performance ed efficienza energetica, dimostrando che la vera sostenibilità dell'AI risiede nell'ottimizzazione del rapporto tra l'algoritmo e i vincoli fisici dell'hardware.

2. Referenced Work

La letteratura sull'impatto ambientale dell'intelligenza artificiale negli ultimi anni è aumentata in maniera considerevole, tuttavia vi sono delle lacune che questo lavoro punta di colmare. Il lavoro di Banshir et al. (2024) [5] valuta come l'adozione su larga scala dell'IA solleva urgenti preoccupazioni riguardo alle sue implicazioni climatiche e di sostenibilità, rendendo necessaria una mappatura accurata dei consumi necessari per i modelli generativi.

Tuttavia, gran parte degli sforzi di ricerca si è storicamente concentrata sulla fase di addestramento dei modelli. Ad esempio di studio di Ariyanti et al. [6] analizza in dettaglio il trade-off tra il consumo energetico e i parametri di configurazione durante il training dell'IA, proponendo linee guida per le policy ambientali. Sebbene fondamentale come lavoro si tende a tralasciare o sottovalutare l'impatto che deriva dall'utilizzo quotidiano e ripetuto dei modelli una volta addestrati.

Più di recente, la letteratura ha iniziato a riconoscere la necessità di un approccio che comprendesse di valutare tutti i parametri. Oliverira et al. [7] hanno condotto una revisione sistematica che mira a valutare l'intero ciclo

di vita delle IA, pur evidenziando l'importanza di valutare tutte le fasi operative, la maggior parte delle analisi riportate in letteratura continua a fare riferimento a infrastrutture di calcolo centralizzate, basandosi su stime relative ai grandi datacenter. In questo contesto, il presente lavoro si inserisce colmando una specifica lacuna letteraria. Discostarsi dall'analisi macroscopica dei datacenter e dalle misurazioni del training e concentrarsi sulle problematiche legate alla fase di inferenza dal lato dell'utente finale. A differenza di approcci tradizionali, la valutazione viene condotta testando diversi LLM in esecuzione su hardware consumer.

3. Methodology

Al fine di garantire assoluto rigore nelle valutazioni fatte e riproducibilità dei risultati, la metodologia si articola in più fasi: la definizione di una nuova metrica di valutazione, il setup dell'hardware e del software, la selezione dei modelli di AI ed infine il protocollo di esecuzione per l'analisi statistica.

3.1. Definizione della metrica di normalizzazione

Per superare le problematiche legate alla lettura tradizionale dei token, questo studio introduce una metrica basata sulla dimensione del file generato. Da precisare fin da subito che i valori dei consumi energetici e di impatto ambientale riportati in questa sezione fungono esclusivamente da baseline teorica e derivano interamente dalla letteratura scientifica di settore e non da misurazioni condotte localmente in questo studio.

Per i file testuali si è valutata prima la dimensione del singolo token.

È doveroso, a questo punto, fare una precisazione architettonica sul funzionamento dei tokenizer. Il token non è unità di misura statica, bensì una variabile strettamente dipendente dal modello, in quanto modelli differenti presentano vocabolari di dimensioni diverse. Un vocabolario più ampio permette al modello di comprimere la stessa parola in un numero inferiore di frammenti, di conseguenza confrontare l'efficienza energetica valutando i consumi per token nativi premierà falsamente le architetture con vocabolari più ampi, oscurando il reale assorbimento energetico.

Per neutralizzare questo fattore di confondimento, nel presente studio si è deciso di mantenere il parametro convenzionale suggerito da OpenAI [8], secondo cui un token equivale a circa 4 caratteri.

Questa imposizione metodologica funge da proxy matematico per tutte le architetture testate costringendo i modelli su uno stesso piano uguale per tutti, in questo modo le fluttuazioni nei consumi potranno essere imputate unicamente all'effettivo sforzo computazionale e non alla mera efficienza del vocabolario, considerando che 1 byte equivale ad un singolo carattere si ricava che:

$$\text{Token in un MB} = \frac{1 \times 10^6 \text{ Byte}}{4 \text{ Byte/Token}} = 250.000 \text{ Token}$$

Quindi in un MB ci sono circa 250.000 token, il che è una stima, valutando che in una risposta data dai LLM ci sono circa 154 token e considerando che per tali valori si consumano circa 0,24 Wh (864 Joule) [9] per raggiungere il MB e calcolarne i consumi sarà necessario valutare:

$$\frac{250.000 \text{ Token}}{154 \text{ Token}} \times 0,24 \text{ Wh} \approx 389 \text{ Wh}$$

che convertiti diventano 1.402.000 J = 1,4 MJ.

Al fine di determinare l'impronta carbonica, il valore 0,389 kWh è stato moltiplicato per il fattore di emissione medio della rete elettrica statunitense aggiornato al 2025, pari a circa 350 g/kWh [10], ottenendo un'emissione stimata pari a 136,15 gCO₂ per singolo MB di testo generato, mentre per quanto riguarda i consumi idrici vengono stimati circa 0,26 ml di acqua per il prompt mediano [9], quindi Consumo d'acqua per 1 MB = $\frac{250.000}{154} \times 0,26 \text{ ml} = 422 \text{ ml}$ di acqua

È essenziale sottolineare che questi calcoli matematici riflettono la letteratura standard attualmente predominante nel settore. Questo tipo di approccio implica che il costo per singolo token rimanga costante, tale stima funge solo da baseline teorica dato che come verrà dimostrato da questo studio, l'assunzione di una linearità risulta gravemente fallace in contesti operativi reali, rendendo questa baseline un termine di paragone necessario proprio per evidenziare i limiti attuali dei modelli di valutazione.

Nella realtà empirica e in particolare per la architettura Transformer, i valori riferiti al MB non rappresentano una singola generazione continua, fisicamente impossibile per limiti fisici, ma il costo cumulativo di "n" inferenze di taglia medio-bassa.

3.2. Setup hardware e strumenti di misurazione

Le misurazioni sono state condotte su un laptop di fascia alta, HP OMEN Trascend 16, con una GPU NVIDIA GeForce RTX 4070 (Laptop) con 8 GB di VRAM dedicata e 16 GB di RAM di sistema forniti da un INTEL core i9, tale configurazione è stata scelta come rappresentativa dell'hardware consumer, ideale per testare i limiti della memoria durante l'esecuzione di modelli linguistici locali.

Il software è stato scritto al fine di poter garantire la standardizzazione del test ed evitare interferenze umane attraverso l'automatizzazione dello script Python. I modelli valutati sono:

- llama3.2 da 3.2B di parametri con quantizzazione Q4_K_M
- qwen2 da 14.8B di parametri con quantizzazione Q4_K_M
- llama3.1 da 8B di parametri con quantizzazione Q4_K_M
- mistral da 7.2B di parametri con quantizzazione Q4_K_M
- qwen2 da 7.6B di parametri con quantizzazione Q4_K_M
- phi3 da 3.8B di parametri con quantizzazione Q4_0
- gemma2 da 27.2B di parametri con quantizzazione Q4_0

(Successivamente in questo lavoro verranno riportati i parametri indicati nella nomenclatura ufficiale dei modelli)

Il codice si avvale della libreria *llangchain ollama* e del framework *CodeCarbon* [11] per monitorare la telemetria energetica.

Per garantire che i modelli venissero valutati in base a parametri giusti per tutte le ripetizioni sono stati impostati i seguenti parametri per benchmark quali MMLU, SQuAD ed HellaSwag:

- temperature=0.6: Regola la creatività del modello,
- num_predict=512: è il numero massimo di token utilizzabili,

- num_ctx=2048: Definisce la dimensione della "finestra di contesto",
- repeat_penalty=1.2: è una penalità per evitare che vengano ripetute parole,
- top_p=0.95: Elimina le parole statisticamente troppo improbabili,
- top_k=20: Valuta solo le 20 parole più probabili per la scelta,

Mentre per benchmark che richiedevano una rigidità di risposta più restrittiva come GSM8K e HumanEval si è utilizzata una temperature pari a 0, così da annullare il coefficiente di creatività.

Il ciclo operativo è stato strutturato al fine di iterare in sequenza le domande del benchmark su ciascun modello. Durante l'esecuzione il sistema isola i processi attivando un tracker definito "EmissionTracker", che campiona i dati ambientali, come assorbimento in Joule, le stime di CO_2 e i tempi di esecuzione, per poi salvarli in un file CSV.

Per evitare fenomeni indesiderati dovuti a surriscaldamento e per garantire che ogni iterazioni consenta la trasparenza dei dati è stato inserito un cooldown forzato al termine di ogni singolo modello e uno al termine di ogni richiesta ricevuta che riporta la temperatura post-operazione a quella pre-test.

3.3. Protocollo di esecuzione e analisi statistica

Il carico di lavoro consiste nell'utilizzo di 5 benchmark, ovvero: GSM8K [12], MMLU [13], SQuAD [14], HelloSwag [15] e HumanEval [16]. Il test viene ripetuto per 3 volte ed è composto da 100 domande (scelte in maniera casuale ma uguali per ogni ripetizione) per ogni benchmark. Il numero totale di inferenze consente di garantire la validità statistica delle misurazioni e consentire il calcolo della media, deviazione standard e intervalli di confidenza al 95%.

Per evitare che il calore residuo di un test precedente influenzasse prove successive è stato applicato un cooldown forzato al termine di ogni run e al passaggio da un modello all'altro in maniera tale da riportare l'hardware ad una temperatura basale calcolata all'inizio dei test.

L'analisi dei dati si avvale anche del Coefficiente di Variazione, questo viene calcolato come il rapporto tra la deviazione standard ($\sigma = \sqrt{\frac{1}{N-1} \sum (x_i - \mu)^2}$) e la media campionaria ($\mu = \frac{1}{N} \sum x_i$), spesso espressa in forma percentuale:

$$CV = \frac{\sigma}{\mu} \times 100$$

Questo è un indice di stabilità utilizzato per valutare quanto effettivamente tra una domande ed un'altra, tra una run ed un'altra le risposte cambino.

3.4. Limitazioni metodologiche

Il presente studio presenta alcune limitazioni che è necessario dichiarare al fine di garantire una corretta interpretazione dei risultati.

Inanzitutto, le misurazioni effettuate sono state condotte su un singolo sistema hardware, che è rappresentativo della fascia alta degli hardware consumer ma che non è generalizzabile a configurazioni con VRAM diverse, in particolare la soglia dell'offloading è specifica per 14GB di VRAM. A ciò si aggiunge che i modelli analizzati presentano architetture sottostanti eterogenee, pertanto le differenze nei consumi potrebbero essere attribuibili anche a questo fattore, il quale non è il soggetto di questo studio. Sul fronte della valutazione ambientale è necessario dichiarare una differenza nei fattori di conversione utilizzati per il calcolo dell'impronta carbonica. Mentre la baseline teorica adotta il fattore $350g/kWh$ come standard di riferimento della rete elettrica statunitense, le stime delle emissioni di CO_2 rilevate da CodeCarbon si basano su un fattore di emissione medio basato sulla posizione geografica dell'utente, che varia sia per il luogo che per il momento nel quale viene effettuato il test, introducendo un fattore di incertezza che però non compromette la validità dei confronti effettuati.

Passando alla metrica proposta basata sul MB valuta esclusivamente il volume quantitativo dell'output testuale, omettendone la densità semantica o il reale valore informativo. Sebbene l'analisi sull'accuratezza dei benchmark 4.4 funga da controllo per la validità dell'output, la misurazione formale della qualità semantica esula dagli scopi di questo testo, demandandone l'integrazione a futuri studi.

A livello analitico la derivazione matematica della baseline teorica 3.1 si affida ad un'extrapolazione lineare che, partendo da output medi dati dalla letteratura di circa 154 token, impiega fattori moltiplicativi molto grandi per scalare sul MB, questo processo espone inevitabilmente la stima teorica ad amplificare gli errori delle fluttuazioni che possono avvenire nel sistema. Tuttavia il presente studio presenta questa metrica come strumento di comparazione, quindi questa intinseca instabilità non inficia la validità delle misurazioni successive, ma al contrario, certifica l'inaffidabilità delle macro-stime e rafforza la necessità dell'utilizzo di un framework di misurazione dinamico.

È altrettanto cruciale contestualizzare l'origine dei dati di letteratura utilizzati come termine di paragone iniziale. Tali stime derivano da datacenter hyperscale, dotate di attrezzature particolari ed altamente specializzate. Il confronto tra queste strutture e l'hardware consumer risulta asimmetrico, a questo accostamento non mira a sminuire l'efficienza del Cloud, bensì a quantificare esattamente le differenze tra il costo ambientale che si genera decentralizzando il calcolo, dimostrando come le stime dei provider non siano minimamente rappresentative dell'impatto reale sui dispositivi.

In ultima analisi, si sottolinea come l'equivalenza fissa di 4 byte per token omette le differenze architetturali dei tokenizer dei modelli testati, le dimensioni del vocabolario variano drasticamente, passando dai 32.064 token di Phi-3 [17], ai 128.256 di LLama3 [18], fino ai 151.643 di Qwen 2.5 [19] e ai 256.000 di Gemma2 [20]. Tale eterogeneità comporta che il medesimo contenuto informativo venga frammentato in un numero variabile di token, rendendo il conteggio assoluto privo di valore comparativo tra modelli differenti.

Questo limite conferma ulteriormente come la dimensione del file in MB, essendo un dato universale, si configuri come unica standardizzazione oggettivamente comparabile per l'utente finale. Va inoltre notato che i benchmark utilizzati non esauriscono la totalità dei dataset standardizzati, limitando la comparabilità con altri lavori, ma non compromettendone i risultati sui maggiori casi d'uso.

4. Results

4.1. Analisi energetica e temporale

I dati derivanti dai test mostrano come all'aumentare della grandezza dei modelli ci sia un aumento sia nei consumi energetici che nell'aumento dei tempi di risposta.

Come mostrato nel grafico 1, che combina Energia spesa e Tempo impegnato, con valori esplicitati nella tabella 1 il passaggio da modelli compatti come Llama3.2 (3B) a modelli enormi con Gemma 2 (27B) comporta un aumento drammatico sia dei tempi di esecuzione che dell'energia complessiva consumata, misurata in Watt/ora (Wh)




Figure 1: La rappresentazione grafica degli intervalli di confidenza al 95% su campioni di tali dimensioni comporta un'inevitabile instabilità nelle stime di varianza e poggia su un'assunzione difficilmente verificabile. Pertanto, le barre riportate vanno interpretate in senso euristico, come indicatori della dispersione osservata durante i test, piuttosto che come rigorosi limiti probabilistici assoluti.

L'inclusione degli intervalli di confidenza al 95% sulle barre di misurazione evidenziano il fatto che i modelli più piccoli siano abbastanza costanti, contrapposta al drastico aumento dell'errore statistico nei modelli più grandi, sinonimo di una crescente fatica computazionale da parte del sistema locale nel gestire il carico.

Tuttavia, c'è da specificare che le medie globali qui presentate fondono volutamente carichi di lavoro estremamente eterogenei tra loro. Questa presentazione macroscopica possiede il fine di valutare la stabilità sistemica dell'hardware sotto stress. Essa inevitabilmente, oscura la variabilità dei consumi legata alla specifica del singolo task.

Come verrà ampiamente discusso e disaggregato nell'analisi sui costi dei token 4.5, l'apparente stabilità

delle medie globali non deve trarre in inganno, l'impatto energetico reale subisce fluttuazioni severe non appena si isolano i singoli benchmark, dimostrando che l'uso di macro-medie, se non adeguatamente contestualizzato risulta fuorviante per una stima precisa.

Modello	Durata (s)	Energia Consumata (Wh)
Gemma 2 (27B)	33.0 ± 1.5	0.61
Llama 3.1 (8B)	10.5 ± 0.2	0.21
Llama 3.2 (3B)	8.5 ± 0.1	0.15
Mistral (8B)	8.0 ± 0.2	0.18
Phi-3 Mini (3B)	7.5 ± 0.1	0.17
Qwen 2.5 (14B)	19.5 ± 1.0	0.44
Qwen 2.5 (7B)	10.0 ± 0.2	0.21

Table 1: Valori medi e distacco massimo per durata ed energia (Wh). La doppia spaziatura evidenzia il distacco tra intestazioni e dati sperimentali.

Dal calcolo del CV% si nota come più ci si avvicini ai limiti dell'hardware più aumentano le fluttuazioni, come si può vedere dai dati di Qwen2.5 (14B) che rappresenta il filo del rasoio, per poi ritornare a livelli più bassi quando viene trattato Gemma 2 (27B) ma questo come già visto a discapito dell'efficienza energetica.




Figure 2

4.2. Impatto ambientale e impronta al carbonio

Le emissioni di anidride carbonica (CO_2) stimate dal framework CodeCarbon seguono proporzionalmente l'assorbimento energetico (3). Tuttavia per contestualizzare questo costo ambientale e uniformarlo all'analisi

dimensionale considerata in precedenza, è essenziale normalizzare tale impronta non solo in base alla singola query, ma rispetto al volume di dati generato, ovvero il MegaByte (MB).

Considerando che 1 MB di testo corrisponde a circa un milione di caratteri (assunti convenzionalmente a circa 250.000 token testuali), è possibile proiettare l'efficienza dei singoli LLM. Generare 1 MB di output testuale utilizzando un modello sovradimensionato per l'hardware come Gemma 2 supera di almeno 5 volte l'impronta carbonica rispetto ad un modello come Llama 3.1 (8B). Questo trade-off dimostra come la scelta del modello influisca sull'impronta ecologica finale in maniera altrettanto marcata rispetto alla fonte di produzione dell'energia elettrica stessa.




Figure 3

Modello	Emissioni CO_2 (g)
Gemma 2 (27B)	0.191
Llama 3.1 (8B)	0.066
Llama 3.2 (3B)	0.048
Mistral	0.056
Phi-3 Mini	0.052
Qwen 2.5 (14B)	0.136
Qwen 2.5 (7B)	0.067

Table 2: Valori medi massimo dalla media per le emissioni di anidride carbonica (CO_2), espresse in grammi (g), per una singola inferenza.

4.3. Analisi del carico hardware e stabilità

La figura 4 mostra visivamente il punto critico dell'inferenza utilizzata localmente: il collo di bot-

taglia della memoria video (VRAM). Per i modelli al di sotto dei 14B di parametri, il modello non solo risiede totalmente all'interno della VRAM ma è in grado di non stressare particolarmente le componenti. Questo consente di completare il calcolo alla massima velocità possibile, con il modello da 14B che rappresenta il limite massimo della VRAM. Al contrario, quando si eseguono modelli come Gemma 2(27B), la VRAM si satura completamente. Qui avviene uno switch da VRAM a RAM con la CPU che deve coordinare il trasferimento dei dati, questo non solo come si può vedere cambia le gerarchie di utilizzo delle componenti, ma compromette drasticamente la Quality of Service (QoS).




Figure 5

Quindi ciò indica che il superamento dei limiti strutturali è sì possibile ma è un problema a livello ecologico, perché la GPU lavora male e al minimo delle sue possibilità.



Figure 4

Un'ulteriore conferma di questo avvenuto Offloading è la potenza media che non segue il trend crescente degli altri modelli, questo dato unito al tempo impiegato visto in precedenza, non indica efficienza ma indica che l'hardware lavora molto più lentamente rispetto agli altri modelli.

4.4. Valutazione dell'accuratezza

Per determinare l'efficacia reale dei modelli, l'analisi energetica e dell'hardware deve essere necessariamente comparata con le prestazioni che hanno mostrato nei test. Per fornire un ranking prestazionale di massima, la Tabella 3 riporta un punteggio medio aggregato per ciascun modello, questa media macroscopica risulta funzionale e necessaria per delineare una gerarchia generale delle capacità dei modelli, utile anche per valutazione successive.

Modello	Accuratezza Media (%)
Phi-3 Mini	41.80
Llama 3.2 (3B)	58.14
Qwen 2.5 (7B)	77.077
Mistral	59.48
Llama 3.1 (8B)	66.80
Qwen 2.5 (14B)	82.52
Gemma 2 (27B)	82.33

Table 3: Accuratezza media complessiva ottenuta dai modelli sui 5 benchmark, misurata in percentuale di risposte corrette.




Figure 6

I modelli sotto i 3B consumano pochissimo ma crollano di accuratezza, Gemma 2 (27B) consuma tantissimo ma ha un'accuratezza inferiore rispetto a Qwen2.5 (7B) e (14B). Questi dati mostrano come effettivamente più parametri non significhi necessariamente una migliore risposta, ma anzi più parametri vengono utilizzati più si aumentano i consumi senza effettivamente migliorare la validità delle risposte.

Il modello Qwen 2.5 (7B) rappresenta lo sweet spot ottimale, riuscendo ad ottenere ottime valutazioni nell'accuratezza con una frazione del costo energetico dei due modelli maggiori.

Utilizzando una heatmap è possibile visualizzare anche come i 7 modelli si siano comportati nei 5 benchmark presi singolarmente.




Figure 7

4.5. Il costo dei Token

Prima di valutare l'efficienza elettrica netta, la Figura 8 illustra quanto un modello scriva in generale, evidenziando come Phi-3 Mini generi spontaneamente il numero maggiore di token (265), mentre Gemma 2 (27B) si attesti sul valore più basso (73). Per comprendere l'origine di queste lunghezze, la Figura 11 disaggrega la densità degli output per singolo benchmark, confermando come task intensivi quali HumanEval, MMLU e GSM8K spingano le architetture a risposte più lunghe rispetto ad altri benchmark.

Un'ulteriore risultato di rilievo che emerge dalle analisi svolte riguarda il peso dei token in termini energetici. Come anticipato nella metodologia 3.1, ancorando convenzionalmente il peso del singolo token a 4 byte per neutralizzare le differenze strutturali dei vari vocabolari, emerge un paradosso empirico, a parità di volume informativo prodotto, non tutti i token possiedono lo stesso peso energetico.

Tradizionalmente si tende ad utilizzare una stima di assorbimento lineare quando si studiano i datacenter, in quanto non è possibile valutare le fluttuazioni su singole richieste differenti.

Lo studio in locale invece consente di studiare i dati in maniera più specifica e settorializzare in base a richieste diverse e modelli diversi.




Figure 8

Al fine di validare la metrica normalizzata introdotta precedentemente 3.1, i dati ottenuti sono stati proiettati sul volume di 1MB (equivalenti a 250.000 token testuali circa) ed utilizzando il numero medio di token prodotto da ciascun modello è stato possibile estrapolare il fattore moltiplicativo necessario per raggiungere il MB.

Come si evince dalla tabella comparativa 4 la distanza tra i modelli si amplifica drammaticamente quando si valuta la densità informativa reale. Mentre la baseline teorica della letteratura faceva una stima basata sui datcenter, le misurazioni empiriche in locale mostrano un dato altamente frammentato. Modelli compatti mostrano un'efficienza estrema, risultando addirittura più ecologici della stima teorica, al contrario modelli più grandi come Gemma2 (27B) porta consumi decisamente maggiori. Questo scarto evidenzia come l'inefficienza architetturale su hardware limitato moltiplichi l'impatto ambientale finale, confermando la necessità di una metrica basata sull'output effettivo e non sulla sola infrastruttura.

Table 4: Applicazione empirica della metrica per MB stima dell'energia e delle emissioni necessarie per generare 1 MB di output.

Modello	Token Medi Generati	Energia per 1 MB (Wh)	Emissioni per 1 MB (gCO ₂)
Phi-3 Mini	265	160	49
Llama 3.2 (3B)	170	220	70
Mistral (7.2B)	163	276	85
Qwen 2.5 (7B)	175	300	95
Llama 3.1 (8B)	148	354	111
Qwen 2.5 (14B)	182	604	186
Gemma 2 (27B)	73	2088	654




Figure 9

Incrociando questo volume di output con i consumi elettrici assoluti ricavati dal monitoraggio, si osserva che il costo elettrico necessario per produrre un singolo token subisce variazioni drammatiche in stretta correlazione con la complessità dei task sottoposti e il rapporto tra fase di generazione e di elaborazione del prompt.

Un'anomalia evidente emerge quando si valuta il benchmark HellaSwag, sebbene sia puramente testuale registra il costo per token più alto in assoluto, specialmente per Gemma2. Questo fenomeno è riconducibile al cosiddetto effetto **prefill**, ovvero il modello è costretto a processare un contesto molto lungo ma generando in risposta soltanto una lettera. Di conseguenza il consumo della fase di elaborazione si riflette su quell'unica lettera generata facendo schizzare la metrica risultante.

Discorso diverso, ma con risultati simili, lo si ha con la sottomissione di prompt logico-matematici o di programmazione (come GSM8K o HumanEval), che innescano obbligatoriamente logiche di ragionamento avanzate. Quando un'architettura compatta entra in difficoltà (come nel caso di Phi3), i tempi di elaborazione si allungano, ma la GPU continua ad assorbire energia nonostante alla fine il numero di token prodotti sia molto basso, questo genera chiaramente uno scompenso evidente rispetto a task più semplici. Per i modelli pesanti come Gemma2 si aggiunge anche la problematica precedente dello switch tra VRAM e RAM, paralizzando ulteriormente i consumi assoluti.




Figure 10

Proprio alla luce di queste variazioni contestuali che l'utilizzo di medie globali può rivelarsi fuorviante, seguendo l'approccio della letteratura andassimo a calcolare il costo energetico medio globale per la generazione di un singolo token, otterremmo per Gemma 2 un valore anomalo di $47035\mu Wh$. Più che indicare un efficienza netta, questo macro dato aggregato assorbe e nasconde le inefficienze estreme causate dal memory swapping e dall'effetto prefill, staccando nettamente gli altri modelli citati.




Figure 11

Questa scoperta porta una ricaduta pratica e teorica fondamentale per lo sviluppo di metriche innovative per le IA eco-sostenibili, la stima dell'impatto ambientale di un LLM non può fondarsi esclusivamente sul volume del testo di output. Qualsiasi valutazione rigorosa della sostenibilità dovrà necessariamente implementare un fattore di controllo legato allo sforzo cognitivo e alla com-

plessità del prompt originale, inaugurando di fatto un nuovo paradigma di misurazione dinamica per tutto il sistema.

5. Discussion

5.1. Scelta della grandezza dei modelli

L'analisi tra le prestazioni cognitive e l'assorbimento energetico smentisce, nel contesto dell'inferenza locale, l'idea secondo cui un maggior numero di parametri garantisca sempre output migliori (*Bigger is Better*). Come evidenziato dai dati empirici, Gemma 2 (27B) ottiene un accuratezza media elevata (82,33% circa), ma subisce un vero e proprio tracollo energetico rispetto ad un modello più compatto come Qwen 2.5 (14B) il quale presenta un accuratezza media pressoché identica (82,52% circa). È doveroso però riconoscere, per rigore metodologico, che questo scenario preseta un confondimento tra l'architettura dei modelli, la loro dimensione e lo schema di quantizzazione adottato (Q4_0 per Gemma2 e Q4_K_M per Qwen 2.5). Dal punto di vista puramente teorico servirebbe il medesimo paradigma di quantizzazione, tuttavia in ambiente locale questa eterogeneità rende ancor più chiare le limitazioni a cui sono sottoposti gli hardware consumer. Ovvero, per allocare su una VRAM da 8GB un modello da 27 miliardi di parametri c'è la necessità di quantizzazioni più aggressive che, inevitabilmente, peggiorano la qualità delle risposte. Mentre modelli più compatti permettono l'adozione di schemi di quantizzazioni più sofisticati, che riescono a preservare meglio le capacità cognitive dei modelli.

Si deduce quindi che, in locale, la scelta di un modello sovradimensionato non rappresenti un vantaggio competitivo, ma si traduce in un calo delle prestazioni operative e un ingiustificabile spreco di risorse energetiche.

5.2. Il collo di bottiglia architetturale: VRAM e Memory Bandwidth

Le analisi effettuate non sono state effettuate in datacenter o ambienti controllati, il tutto al fine di valutare come l'IA possa reagire su hardware consumer. I problemi da valutare sono differenti, per i datacenter va considerato il raffreddamento delle componenti o i consumi d'acqua, mentre su dispositivi personali la cosa più importante da tenere in considerazione è la gestione della memoria.

I risultati ottenuti dimostrano come i fenomeni di Data Starvation e Memory Swapping rappresentano la vera barriera alla sostenibilità dell'IA locale. Quando un modello supera le capacità della VRAM dedicata, il sistema è costretto a delegare il trasferimento dei pesi alla CPU e alla RAM di sistema attraverso il bus PCIe. Come evidenziato da ?? che rappresenta la potenza media assorbita dalla GPU e da ?? che indica come viene ripartito il consumo delle risorse per le componenti hardware, la GPU si ritrova a dover lavorare in uno stato di attesa inefficiente, abbattendo inesorabilmente la Quality of Service (QoS). Questo comportamento certifica un cambio di paradigma fondamentale per la ricerca futura nell'ambito dell'IA per i PC, il limite operativo e il conseguente impatto ambientale non sono dettati soltanto dalla capacità computazionale del processore, bensì dalla larghezza di banda della memoria.

5.3. Verso una metrica di sostenibilità dinamica

Si potrebbe pensare che acquistare device di ultima generazione o l'utilizzo di fonti energetiche a basso impatto carbonico siano sufficienti per mitigare l'impatto ambientale. Tuttavia, i risultati di questo studio forniscono nuove informazioni a riguardo, dimostrando come una scelta mirata dei modelli da utilizzare rivesta un'importanza fondamentale.

Questo concetto emerge con chiarezza grazie all'utilizzo della metrica normalizzata introdotta nella metodologia 3, i megabyte (MB) dei dati generati. L'uso di un volume di dati preciso e semplicemente reperibile consente di valutare l'efficienza a parità di lavoro utile. Quindi si osserva facilmente che l'utilizzo di architetture come Gemma 2 (27B) o Qwen 2.5 (14B) per task non complesse costituisce un errore strategico ed ecologico.

A parità di output, l'adozione di un modello ottimizzato come Qwen 2.5 (7B) è in grado di abbattere le emissioni di CO_2 rispetto ai suoi concorrenti sovradimensionati, mantenendo però un'ottima accuratezza nelle risposte. Questo scarto enorme mostra come l'ottimizzazione e il dimensionamento dell'algoritmo rispetto al task richiesto rappresentano, allo stato attuale, il più potente strumento in controllo dell'utente finale. Non vi è quindi una giustificazione ingegneristica per l'impiego di modelli ad alte prestazioni, in contesti ordinari, ma al contrario, la vera sostenibilità dell'IA decentralizzata risiede nel promu-

overe algoritmi che si allineino con la potenza di calcolo necessaria a risolvere il task.

Un'ulteriore risultato fondamentale emerso da questa analisi è la confutazione del modello lineare di stima energetica per gli LLM. La baseline teorica calcolata nella metodologia 3.1 risulta troppo semplicistica ed è basata sull'assunto che il costo di un token sia costante. Tuttavia, le nostre rilevazioni dimostrano inequivocabilmente il contrario, il costo dei token, in base a determinati fattori, subisce variazioni drammatiche. Questo contrasto tra la teoria e la pratica certifica che l'estrapolazione lineare dei consumi basata solo sul conteggio dei token sia inefficace ed inaccurata, dimostrando così il valore critico della metrica per MB qui proposta e qualsiasi valutazione rigorosa della sostenibilità non può prescindere da una misurazione dinamica che tenga conto del reale sforzo cognitivo e fisico richiesto dall'hardware.

5.3.1. Un framework di misurazione multidimensionale

Al fine di superare i limiti dell'approccio lineare, i dati raccolti dimostrano la necessità di evolvere la semplice metrica dimensionale (MB) verso un framework di misurazione multidimensionale. Affinché la valutazione dell'impatto ecologico in scenari reali sia accurata, il peso del file generato deve essere contestualizzato attraverso due nuovi vettori di analisi emersi da questo studio.

Come evidenziato dalle anomalie di consumo nei task logico-matematici e dai fenomeni di prefill, la sola dimensione dell'output non basta. Modelli sottoposti a prompt complessi consumano elevata energia nella fase di elaborazione, pur generando file finali di pochi byte, una metrica futura dovrà integrare un fattore di compensazione che pesi il dominio di applicazione del prompt.

Inoltre il superamento della soglia di VRAM disponibile introduce un ulteriore coefficiente da tenere in considerazione, come osservato nell'esecuzione di modelli con molti parametri, questa inefficienza energetica andrebbe ad aggiungersi all'impronta carbonica valutata. Questo parametro dovrà diventare una variabile fissa nelle stime di sostenibilità per hardware consumer.

In conclusione, la misurazione basata sui MB rappresenta il parametro più tangibile e pragmatico dal lato utente, ma l'impatto ambientale reale è un prodotto dinamico tra volume dei dati generati, la complessità intrinseca della richiesta e i limiti fisici dell'architettura ospitante.

5.4. Linee guida per l'utente finale

Viste le criticità architetture ed ecologiche espresse fin'ora, serve definire delle linee guida destinate all'utilizzatore finale. Per dare una valutazione oggettiva verranno fatti ragionamenti basati sulla valutazione dell'accuratezza effettuata in precedenza 7.

L'analisi dei singoli benchmark rivela che l'impiego di modelli ultra compatti (Sotto i 4B, tipo Llama 3.2 e Phi-3) è non solo sufficiente, ma fortemente consigliato per task di natura estrattiva o di comprensione testuale diretta (Benchmark SQuAD e HellaSwag). In questi domini specifici i modelli leggeri non solo sono validi, ma possono competere con le loro controparti più pesanti, ma abbattendo quasi del tutto la loro impronta al carbonio.

Tuttavia la medesima tabella evidenzia il limite di tali architetture, presentano un crollo dei successi non appena il prompt diventa più complesso, come generazione di codice o logica matematica (Benchmark HumanEval, GSM8K, MMLU). Per questi scenari di calcolo avanzato, i dati mostrano come i modelli di fascia intermedia (7B - 8B) come i veri sweet spot dell'inferenza, questi modelli riescono a dominare i task logico matematici mantenendo l'intero carico computazionale all'interno degli 8GB di VRAM, offrendo il compromesso perfetto da consumi ed accuratezza.

Si evince, in fine, che l'esecuzione in locale di modelli troppo grandi (quelli testati dai 14B in su) per task diretti e sequenziali non solo è deleterio, ma è da disincentivare, perché il margine di incremento qualitativo (o addirittura il degrado prestazionale causato da una quantizzazione troppo estrema) non giustifica in alcun modo l'incremento dei consumi.

È da precisare, tuttavia, che questa raccomandazione non costituisce un disincentivo assoluto, l'utilizzo di architetture di fascia alta per un hardware consumer (27B+) rimane essenziale per determinati casi d'uso avanzati non trattati in questo studio, quali architetture RAG, inferenza batch o elaborazione di contesti estremamente lunghi, scenari in cui la precisione complessa giustifica l'investimento energetico e computazionale. In assenza di tali necessità, il disallineamento tra la grandezza dell'architettura e i limiti fisici si conferma, nell'uso quotidiano, una primaria causa di spreco negli ecosistemi IA locali.

6. Summary and Conclusions

La decentralizzazione dell'IA porta con sé la necessità di dover ricalibrare i paradigmi con cui ne valutiamo l'impatto ecologico. Bisogna discostarsi dalle misurazioni aggregate dei datacenter, questo lavoro ha indagato il reale costo energetico dell'inferenza LLM su hardware consumer, dimostrando come le stime lineari standard risultino inefficaci se non errate quando applicate all'edge IA.

I dati raccolti hanno smentito il principio del costo energetico costante per token, rivelando che il consumo reale è influenzato da fattori dinamici derivanti dallo sforzo cognitivo del prompt e dai limiti fisici dell'hardware. Quindi il vero limite operativo non risiede nella capacità di calcolo puro del processore, ma nella capacità della memoria. La scelta di modelli sovradimensionati quindi, non solo è non utile, ma addirittura deleterio in quanto provoca ingenti consumi energetici al fronte di un miglioramento dell'accuratezza minimo rispetto a modelli che performano meglio.

Di conseguenza, questo lavoro, propone il superamento del mero conteggio dei token in favore di un framework di misurazione multidimensionale basato sui MB, in cui la dimensione del file generato viene ponderata tramite coefficienti legati alla complessità del task e alle penalità architetture.

Le raccomandazioni operative delineano un netto vantaggio per i modelli di fascia intermedia (7B-8B), che rappresentano lo sweet spot ideale tra accuratezza ed efficienza energetica, mantenendo chiaramente il carico computazionale all'interno della VRAM.

Ricerche future dovranno estendere questo approccio integrando metriche di densità semantica del testo e applicando il framework a flussi di lavori multimodali completi.

In conclusione, la vera sostenibilità dell'IA locale non risiede nell'utilizzo indiscriminato di modelli sempre più grandi, bensì nell'esatto allineamento dimensionale tra la complessità dell'algoritmo e i vincoli termodinamici dell'hardware.

Acknowledgements

Thanks to ...

References

- [1] M. Yañez-Barnuevo, Data centers and water consumption (2025). URL <https://www.eesi.org/articles/view/data-centers-and-water-consumption>
- [2] U.S. Environmental Protection Agency, 2025 greenhouse gas emission factors hub (2025). URL <https://www.epa.gov/climateleadership/ghg-emission-factors-hub>
- [3] Electric Power Research Institute (EPRI), Powering intelligence: Analyzing artificial intelligence and data center energy consumption, Tech. Rep. 3002028905 (2024). URL <https://www.epri.com/research/products/000000003002028905>
- [4] A. Zewe, Explained: Generative ai’s environmental impact (2025). URL <https://news.mit.edu/2025/explained-generative-ai-environmental-impact-0117>
- [5] N. Bashir, P. Donti, J. Cuff, S. Sroka, M. Ilic, V. Sze, C. Delimitrou, E. Olivetti, The Climate and Sustainability Implications of Generative AI, An MIT Exploration of Generative AI <https://mit-genai.pubpub.org/pub/8ulgrckc> (mar 27 2024).
- [6] S. Ariyanti, M. Suryanegara, A. S. Arifin, A. I. Nurwidya, N. Hayati, Trade-off between energy consumption and three configuration parameters in artificial intelligence (ai) training: Lessons for environmental policy, *Sustainability* 17 (12) (2025). doi: 10.3390/su17125359. URL <https://www.mdpi.com/2071-1050/17/12/5359>
- [7] A. P. Oliveira, T. Carraquico, C. Martinez-Perez, Beyond efficiency: A systematic review of energy consumption and carbon footprint across the ai lifecycle, *Sustainability* 18 (3) (2026). doi:10.3390/su18031359. URL <https://www.mdpi.com/2071-1050/18/3/1359>
- [8] OpenAI, What are tokens and how to count them?, <https://help.openai.com/en/articles/4936856-what-are-tokens-and-how-to-count-them> (2023).
- [9] Google, Measuring the environmental impact of delivering ai at google scale, Tech. rep., Google Services, technical Report (August 2025). URL https://services.google.com/fh/files/misc/measuring_the_environmental_impact_of_delivering_ai_at_google_scale.pdf
- [10] Environmental Protection Agency (EPA), Emission factors for greenhouse gas inventories, Technical report, Center for Corporate Climate Leadership, gHG Emission Factors Hub (Gennaio 2025).
- [11] B. Courty, V. Schmidt, S. Luccioni, Goyal-Kamal, Marion-Coutarel, B. Feld, J. Lecourt, LiamConnell, A. Saboni, Inimaz, supatomic, M. Léval, L. Blanche, A. Cruveiller, ouminasara, F. Zhao, A. Joshi, A. Bogroff, H. de Lavoreille, N. Laskaris, E. Abati, D. Blank, Z. Wang, A. Catovic, M. Alencon, M. Stęchły, C. Bauer, L. O. N. de Araújo, JPW, MinervaBooks, mlco2/codecarbon: v2.4.1 (May 2024). doi:10.5281/zenodo.11171501. URL <https://doi.org/10.5281/zenodo.11171501>
- [12] K. Cobbe, V. Kosaraju, M. Bavarian, M. Chen, H. Jun, L. Kaiser, M. Plappert, J. Tworek, J. Hilton, R. Nakano, C. Hesse, J. Schulman, Training verifiers to solve math word problems, arXiv preprint arXiv:2110.14168 (2021).
- [13] Y. Wang, X. Ma, G. Zhang, Y. Ni, A. Chandra, S. Guo, W. Ren, A. Arulraj, X. He, Z. Jiang, et al., Mmlu-pro: A more robust and challenging multi-task language understanding benchmark, arXiv preprint arXiv:2406.01574 (2024).
- [14] P. Rajpurkar, J. Zhang, K. Lopyrev, P. Liang, Squad: 100,000+ questions for machine comprehension of text, in: *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing*, 2016, pp. 2383–2392. URL <https://arxiv.org/abs/1606.05250>
- [15] R. Zellers, A. Holtzman, Y. Bisk, A. Farhadi, Y. Choi, Hellaswag: Can a machine really finish your sentence?, in: *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, 2019.
- [16] Q. Peng, Y. Chai, X. Li, Humaneval-xl: A multilingual code generation benchmark for cross-lingual natural language generalization, in: *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, 2024. URL <https://arxiv.org/abs/2402.16694>
- [17] M. Abdin, J. Aneja, H. Awadalla, A. Awadallah, A. A. Awan, N. Bach, A. Bahree, A. Bakhtiari, J. Bao, H. Behl, A. Benhaim, M. Bilenko, J. Bjorck, S. Bubeck, M. Cai, Q. Cai, V. Chaudhary, D. Chen, D. Chen, W. Chen, Y.-C. Chen, Y.-L. Chen, H. Cheng, P. Chopra, X. Dai, M. Dixon, R. Eldan, V. Fragoso, J. Gao, M. Gao, M. Gao, A. Garg, A. D. Giorno, A. Goswami, S. Gunasekar, E. Haider, J. Hao, R. J. Hewett, W. Hu, J. Huynh, D. Iter, S. A. Jacobs, M. Javaheripi, X. Jin, N. Karampatziakis, P. Kauffmann, M. Khademi, D. Kim, Y. J. Kim, L. Kurilenko, J. R. Lee, Y. T. Lee, Y. Li, Y. Li, C. Liang, L. Liden, X. Lin, Z. Lin, C. Liu, L. Liu, M. Liu, W. Liu, X. Liu, C. Luo, P. Madan, A. Mahmoudzadeh, D. Majercak, M. Mazzola, C. C. T. Mendes, A. Mitra, H. Modi, A. Nguyen, B. Norick, B. Patra, D. Perez-Becker, T. Portet, R. Pryzant, H. Qin, M. Radmilac, L. Ren, G. de Rosa, C. Rosset, S. Roy, O. Ruwase, O. Saarikivi, A. Saied, A. Salim, M. Santacrose, S. Shah, N. Shang, H. Sharma, Y. Shen, S. Shukla, X. Song, M. Tanaka, A. Tupini, P. Vaddamanu, C. Wang, G. Wang, L. Wang, S. Wang, X. Wang, Y. Wang, R. Ward, W. Wen, P. Witte, H. Wu, X. Wu, M. Wyatt, B. Xiao, C. Xu, J. Xu, W. Xu, J. Xue, S. Yadav, F. Yang, J. Yang, Y. Yang, Z. Yang, D. Yu, L. Yuan, C. Zhang, C. Zhang, J. Zhang, L. L. Zhang, Y. Zhang, Y. Zhang, Y. Zhang, X. Zhou, Phi-3 technical report: A highly capable language model locally on your phone (2024). arXiv:2404.14219. URL <https://arxiv.org/abs/2404.14219>

- [18] A. Grattafiori, A. Dubey, A. Jauhri, A. Pandey, A. Kadian, A. Al-Dahle, A. Letman, A. Mathur, A. Schelten, A. Vaughan, A. Yang, A. Fan, A. Goyal, A. Hartshorn, A. Yang, A. Mitra, A. Sravankumar, A. Korenev, A. Hinsvark, A. Rao, A. Zhang, A. Rodriguez, A. Gregerson, A. Spataru, B. Roziere, B. Biron, B. Tang, B. Chern, C. Caucheteux, C. Nayak, C. Bi, C. Marra, C. McConnell, C. Keller, C. Touret, C. Wu, C. Wong, C. C. Ferrer, C. Nikolaidis, D. Allonsius, D. Song, D. Pintz, D. Lyschys, D. Wyatt, D. Esiohu, D. Choudhary, D. Mahajan, D. Garcia-Olano, D. Perino, D. Hupkes, E. Lakomkin, E. AlBadawy, E. Lobanova, E. Dinan, E. M. Smith, F. Radenovic, F. Guzmán, F. Zhang, G. Synnaeve, G. Lee, G. L. Anderson, G. Thattai, G. Nail, G. Mialon, G. Pang, G. Cucurell, H. Nguyen, H. Korevaar, H. Xu, H. Touvron, I. Zarov, I. A. Ibarra, I. Kloumann, I. Misra, I. Evtimov, J. Zhang, J. Copet, J. Lee, J. Geffert, J. Vranes, J. Park, J. Mahadeokar, J. Shah, J. van der Linde, J. Billock, J. Hong, J. Lee, J. Fu, J. Chi, J. Huang, J. Liu, J. Wang, J. Yu, J. Bitton, J. Spisak, J. Park, J. Rocca, J. Johnston, J. Saxe, J. Jia, K. V. Alwala, K. Prasad, K. Upasani, K. Plawiak, K. Li, K. Heafield, K. Stone, K. El-Arini, K. Iyer, K. Malik, K. Chiu, K. Bhalla, K. Lakhotia, L. Rantala-Yeary, L. van der Maaten, L. Chen, L. Tan, L. Jenkins, L. Martin, L. Madaan, L. Malo, L. Blecher, L. Landzaat, L. de Oliveira, M. Muzzi, M. Pasupuleti, M. Singh, M. Paluri, M. Kardaş, M. Tsimgoukelli, M. Oldham, M. Rita, M. Pavlova, M. Kam-badur, M. Lewis, M. Si, M. K. Singh, M. Hassan, N. Goyal, N. Torabi, N. Bashlykov, N. Bogoychev, N. Chatterji, N. Zhang, O. Duchenne, O. Çelebi, P. Alrassy, P. Zhang, P. Li, P. Vasic, P. Weng, P. Bhargava, P. Dubal, P. Krishnan, P. S. Koura, P. Xu, Q. He, Q. Dong, R. Srinivasan, R. Ganapathy, R. Calderer, R. S. Cabral, R. Stojnic, R. Raileanu, R. Maheswari, R. Girdhar, R. Patel, R. Sauvestre, R. Polidoro, R. Sumbaly, R. Taylor, R. Silva, R. Hou, R. Wang, S. Hosseini, S. Chennabasappa, S. Singh, S. Bell, S. S. Kim, S. Edunov, S. Nie, S. Narang, S. Raparthy, S. Shen, S. Wan, S. Bhosale, S. Zhang, S. Vandenhende, S. B. Tra, S. Whitman, S. Sootla, S. Collot, S. Gururangan, S. Borodinsky, T. Herman, T. Fowler, T. Sheasha, T. Georgiou, T. Scialom, T. Speckbacher, T. Mihaylov, T. Xiao, U. Karn, V. Goswami, V. Gupta, V. Ramanathan, V. Kerkez, V. Gonguet, V. Do, V. Vogeti, V. Albiero, V. Petrovic, W. Chu, W. Xiong, W. Fu, W. Meers, X. Martinet, X. Wang, X. Wang, X. E. Tan, X. Xia, X. Xie, X. Jia, X. Wang, Y. Goldschlag, Y. Gaur, Y. Babaei, Y. Wen, Y. Song, Y. Zhang, Y. Li, Y. Mao, Z. D. Coudert, Z. Yan, Z. Chen, Z. Papakipos, A. Singh, A. Srivastava, A. Jain, A. Kelsey, A. Shajnfeld, A. Gangidi, A. Victoria, A. Goldstand, A. Menon, A. Sharma, A. Boesenberg, A. Baevski, A. Feinstein, A. Kallet, A. Sangani, A. Teo, A. Yunus, A. Lupu, A. Alvarado, A. Caples, A. Gu, A. Ho, A. Poulton, A. Ryan, A. Ramchandani, A. Dong, A. Franco, A. Goyal, A. Saraf, A. Chowdhury, A. Gabriel, A. Bharambe, A. Eisenman, A. Yazdan, B. James, B. Maurer, B. Leonhardi, B. Huang, B. Loyd, B. D. Paola, B. Paranjape, B. Liu, B. Wu, B. Ni, B. Hancock, B. Wasti, B. Spence, B. Stojkovic, B. Gamido, B. Montalvo, C. Parker, C. Burton, C. Mejia, C. Liu, C. Wang, C. Kim, C. Zhou, C. Hu, C.-H. Chu, C. Cai, C. Tindal, C. Feichtenhofer, C. Gao, D. Civin, D. Beaty, D. Kreymer, D. Li, D. Adkins, D. Xu, D. Testuggine, D. David, D. Parikh, D. Liskovich, D. Foss, D. Wang, D. Le, D. Holland, E. Dowling, E. Jamil, E. Montgomery, E. Presani, E. Hahn, E. Wood, E.-T. Le, E. Brinkman, E. Arcaute, E. Dunbar, E. Smothers, F. Sun, F. Kreuk, F. Tian, F. Kokkinos, F. Ozgenel, F. Caggioni, F. Kanayet, F. Seide, G. M. Florez, G. Schwarz, G. Badeer, G. Swee, G. Halpern, G. Herman, G. Sizov, Guangyi, Zhang, G. Lakshminarayanan, H. Inan, H. Shojanazeri, H. Zou, H. Wang, H. Zha, H. Habeeb, H. Rudolph, H. Suk, H. Aspegren, H. Goldman, H. Zhan, I. Damlaj, I. Molybog, I. Tufanov, I. Leontiadis, I.-E. Veliche, I. Gat, J. Weissman, J. Geboski, J. Kohli, J. Lam, J. Asher, J.-B. Gaya, J. Marcus, J. Tang, J. Chan, J. Zhen, J. Reizenstein, J. Teboul, J. Zhong, J. Jin, J. Yang, J. Cummings, J. Carvill, J. Shepard, J. McPhie, J. Torres, J. Ginsburg, J. Wang, K. Wu, K. H. U. K. Saxena, K. Khadelwal, K. Zand, K. Matosich, K. Veeraraghavan, K. Michelena, K. Li, K. Jagadeesh, K. Huang, K. Chawla, K. Huang, L. Chen, L. Garg, L. A. L. Silva, L. Bell, L. Zhang, L. Guo, L. Yu, L. Moshkovich, L. Wehrstedt, M. Khabsa, M. Avalani, M. Bhatt, M. Mankus, M. Hasson, M. Lennie, M. Reso, M. Groshv, M. Naumov, M. Lathi, M. Keneally, M. Liu, M. L. Seltzer, M. Valko, M. Restrepo, M. Patel, M. Vyatskov, M. Samvelyan, M. Clark, M. Macey, M. Wang, M. J. Hermoso, M. Metanat, M. Rastegari, M. Bansal, N. Santhanam, N. Parks, N. White, N. Bawa, N. Singhal, N. Egebo, N. Usunier, N. Mehta, N. P. Laptev, N. Dong, N. Cheng, O. Chernoguz, O. Hart, O. Salpekar, O. Kalinli, P. Kent, P. Parekh, P. Saab, P. Balaji, P. Rittner, P. Bontrager, P. Roux, P. Dollar, P. Zvyagina, P. Ratanchandani, P. Yuvraj, Q. Liang, R. Alao, R. Rodriguez, R. Ayub, R. Murthy, R. Nayani, R. Mitra, R. Parthasarathy, R. Li, R. Hogan, R. Battey, R. Wang, R. Howes, R. Rinott, S. Mehta, S. Siby, S. J. Bondu, S. Datta, S. Chugh, S. Hunt, S. Dhillon, S. Sidorov, S. Pan, S. Mahajan, S. Verma, S. Yamamoto, S. Ramaswamy, S. Lindsay, S. Feng, S. Lin, S. C. Zha, S. Patil, S. Shankar, S. Zhang, S. Zhang, S. Wang, S. Agarwal, S. Sajuyigbe, S. Chintala, S. Max, S. Chen, S. Kehoe, S. Satterfield, S. Govindaprasad, S. Gupta, S. Deng, S. Cho, S. Virk, S. Subramanian, S. Choudhury, S. Goldman, T. Remez, T. Glaser, T. Best, T. Koehler, T. Robinson, T. Li, T. Zhang, T. Matthews, T. Chou, T. Shaked, V. Vontimitta, V. Ajayi, V. Montanez, V. Mohan, V. S. Kumar, V. Mangla, V. Ionescu, V. Poenaru, V. T. Mihailescu, V. Ivanov, W. Li, W. Wang, W. Jiang, W. Bouaziz, W. Constable, X. Tang, X. Wu, X. Wang, X. Wu, X. Gao, Y. Kleinman, Y. Chen, Y. Hu, Y. Jia, Y. Qi, Y. Li, Y. Zhang, Y. Zhang, Y. Adi, Y. Nam, Yu, Wang, Y. Zhao, Y. Hao, Y. Qian, Y. Li, Y. He, Z. Rait, Z. DeVito, Z. Rosnbrick, Z. Wen, Z. Yang, Z. Zhao, Z. Ma, The llama 3 herd of models (2024). [arXiv:2407.21783](https://arxiv.org/abs/2407.21783). URL <https://arxiv.org/abs/2407.21783>
- [19] Qwen, :, A. Yang, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Li, D. Liu, F. Huang, H. Wei, H. Lin, J. Yang, J. Tu, J. Zhang, J. Yang, J. Yang, J. Zhou, J. Lin, K. Dang, K. Lu, K. Bao, K. Yang, L. Yu, M. Li, M. Xue, P. Zhang, Q. Zhu, R. Men, R. Lin, T. Li, T. Tang, T. Xia, X. Ren, X. Ren, Y. Fan, Y. Su, Y. Zhang, Y. Wan, Y. Liu, Z. Cui, Z. Zhang, Z. Qiu, Qwen2.5 technical report (2025). [arXiv:2412.15115](https://arxiv.org/abs/2412.15115). URL <https://arxiv.org/abs/2412.15115>
- [20] G. Team, M. Riviere, S. Pathak, P. G. Sessa, C. Hardin, S. Bhupatiraju, L. Hussenot, T. Mesnard, B. Shahriari, A. Ramé, J. Ferret, P. Liu, P. Tafti, A. Friesen, M. Casbon, S. Ramos, R. Kumar, C. L. Lan, S. Jerome, A. Tsitsulin, N. Vieillard, P. Stanczyk, S. Girgin,

- N. Momchev, M. Hoffman, S. Thakoor, J.-B. Grill, B. Neyshabur, O. Bachem, A. Walton, A. Severyn, A. Parrish, A. Ahmad, A. Hutchison, A. Abdagic, A. Carl, A. Shen, A. Brock, A. Coenen, A. Laforge, A. Paterson, B. Bastian, B. Piot, B. Wu, B. Royal, C. Chen, C. Kumar, C. Perry, C. Welty, C. A. Choquette-Choo, D. Sinopalnikov, D. Weinberger, D. Vijaykumar, D. Rogozińska, D. Herbison, E. Bandy, E. Wang, E. Noland, E. Moreira, E. Senter, E. Eltyshv, F. Visin, G. Rasskin, G. Wei, G. Cameron, G. Martins, H. Hashemi, H. Klimczak-Plucińska, H. Batra, H. Dhand, I. Nardini, J. Mein, J. Zhou, J. Svensson, J. Stanway, J. Chan, J. P. Zhou, J. Carrasqueira, J. Iljazi, J. Becker, J. Fernandez, J. van Amersfoort, J. Gordon, J. Lipschultz, J. Newlan, J. yeong Ji, K. Mohamed, K. Badola, K. Black, K. Millican, K. McDonell, K. Nguyen, K. Sodhia, K. Greene, L. L. Sjoesund, L. Usui, L. Sifre, L. Heuermann, L. Lago, L. McNealus, L. B. Soares, L. Kilpatrick, L. Dixon, L. Martins, M. Reid, M. Singh, M. Iversen, M. Görner, M. Velloso, M. Wirth, M. Davidow, M. Miller, M. Rahtz, M. Watson, M. Risdal, M. Kazemi, M. Moynihan, M. Zhang, M. Kahng, M. Park, M. Rahman, M. Khatwani, N. Dao, N. Bardoliwalla, N. Devanathan, N. Dumai, N. Chauhan, O. Wahltinez, P. Botarda, P. Barnes, P. Barham, P. Michel, P. Jin, P. Georgiev, P. Culliton, P. Kuppala, R. Comanescu, R. Merhej, R. Jana, R. A. Rokni, R. Agarwal, R. Mullins, S. Saadat, S. M. Carthy, S. Cogan, S. Perrin, S. M. R. Arnold, S. Krause, S. Dai, S. Garg, S. Sheth, S. Ronstrom, S. Chan, T. Jordan, T. Yu, T. Eccles, T. Hennigan, T. Kocisky, T. Doshi, V. Jain, V. Yadav, V. Meshram, V. Dharmadhikari, W. Barkley, W. Wei, W. Ye, W. Han, W. Kwon, X. Xu, Z. Shen, Z. Gong, Z. Wei, V. Cotruta, P. Kirk, A. Rao, M. Giang, L. Peran, T. Warkentin, E. Collins, J. Barral, Z. Ghahramani, R. Hadsell, D. Sculley, J. Banks, A. Dragan, S. Petrov, O. Vinyals, J. Dean, D. Hassabis, K. Kavukcuoglu, C. Farabet, E. Buchatskaya, S. Borgeaud, N. Fiedel, A. Joulin, K. Kenealy, R. Dadashi, A. Andreev, Gemma 2: Improving open language models at a practical size (2024). [arXiv:2408.00118](https://arxiv.org/abs/2408.00118). URL <https://arxiv.org/abs/2408.00118>
- [21] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, I. Polosukhin, Attention is all you need, in: *Advances in Neural Information Processing Systems (NeurIPS)*, 2017. URL <https://arxiv.org/abs/1706.03762>
- [22] J. Shin, A. Hwang, Y. Kim, D. Kim, J. Park, Exploring multimodal diffusion transformers for enhanced prompt-based image editing (2025). URL <https://arxiv.org/abs/2508.07519>
- [23] P. Li, J. Yang, M. A. Islam, S. Ren, Making ai less thirsty: Uncovering the hidden water footprint of ai models, *arXiv preprint arXiv:2304.03271* (2023).
- [24] J. O'Donnell, C. Crownhart, The environmental impact of generative ai is finally coming into focus, *MIT Technology Review* Accessed: 2025-05-20 (May 2025). URL <https://www.technologyreview.com/2025/05/20/1116327/ai-energy-usage-climate-footprint-big-tech/>